

CHUYÊN ĐỀ DỰ ÁN CUỐI KỲ

MÔN LẬP TRÌNH CHO KHOA HỌC DỮ LIỆU

Dành cho 03 nhóm, mỗi nhóm 02 học viên lựa chọn và thực hiện xuyên suốt 08 buổi học

Tài liệu hướng dẫn lựa chọn, triển khai, đánh giá và bảo vệ dự án

MỤC LỤC NỘI DUNG

- I. Khung yêu cầu chung cho dự án cuối kỳ
- II. Sáu chuyên đề để các nhóm lựa chọn
 - Chuyên đề 1. Phân tích sản phẩm và đánh giá thương mại điện tử
 - Chuyên đề 2. Phân tích sắc thái truyền thông theo chủ đề thời sự
 - Chuyên đề 3. Phân tích và gợi ý bất động sản
 - Chuyên đề 4. Phân tích thị trường và gợi ý việc làm
 - Chuyên đề 5. Phân tích kết quả học tập và dự báo nguy cơ sinh viên
 - Chuyên đề 6. Phân tích bán hàng, quản lý tồn kho và phân nhóm khách hàng
- III. So sánh và khuyến nghị lựa chọn chuyên đề
- IV. Các mốc kiểm tra theo 08 buổi
- V. Sản phẩm nộp, thang điểm và quy định sử dụng AI

I. KHUNG YÊU CẦU CHUNG CHO DỰ ÁN CUỐI KỲ

1. Mục đích

Mỗi chuyên đề được thiết kế để hai học viên vừa đọc tài liệu, vừa thực hành, vừa hoàn thiện một sản phẩm có thể chạy được. Dự án phải đi qua đầy đủ quy trình khoa học dữ liệu: xác định bài toán, thu thập dữ liệu, kiểm tra chất lượng, làm sạch, phân tích, trực quan hóa, xây dựng mô hình, đánh giá, báo cáo và thuyết trình.

2. Nguyên tắc lựa chọn phạm vi

- Mỗi nhóm chỉ chọn một chuyên đề và một phạm vi hẹp, cụ thể, có khả năng hoàn thành trong 2 tuần.
- Không đặt mục tiêu “thu thập toàn bộ” một nền tảng lớn; chỉ thu thập một mẫu có kiểm soát.
- Không vượt CAPTCHA, đăng nhập, hạn chế truy cập, token nội bộ hoặc cơ chế chống bot.
- Không thu thập dữ liệu cá nhân nhạy cảm; mã hóa hoặc loại bỏ tên, số điện thoại, email, địa chỉ chi tiết và tài khoản người dùng.
- Mỗi nhóm phải có phương án dữ liệu dự phòng trước khi bắt đầu dự án.

3. Quy mô tối thiểu chung

Thành phần	Yêu cầu
Số nguồn dữ liệu	Ít nhất 02 nguồn hoặc 02 loại tập tin có cấu trúc khác nhau
Số bản ghi	Tối thiểu 1.000 bản ghi sau khi hợp nhất; có thể điều chỉnh với dữ liệu văn bản dài
Số thuộc tính	Tối thiểu 10 thuộc tính, gồm biến số, biến phân loại và biến thời gian
Chất lượng dữ liệu	Phải có dữ liệu thiếu, trùng, sai kiểu hoặc ngoại lệ để xử lý

Thành phần	Yêu cầu
Học máy	Có baseline, ít nhất 02 mô hình có giám sát và 01 bài toán phân cụm hoặc gợi ý
Trực quan hóa	Ít nhất 08 biểu đồ có tiêu đề, nhãn trục và nhận xét

4. Sản phẩm bắt buộc

- 01_problem_and_data.ipynb: mô tả bài toán, câu hỏi nghiên cứu, từ điển dữ liệu và dữ liệu mẫu.
- 02_collection_and_cleaning.ipynb: thu thập, kiểm tra, ghi lỗi và làm sạch dữ liệu.
- 03_edata.ipynb: thống kê mô tả, Groupby/Pivot/Merge và trực quan hóa.
- 04_machine_learning.ipynb: baseline, mô hình, đánh giá và phân tích sai số.
- Mã nguồn Python tổ chức theo hàm và lớp; không viết toàn bộ dự án trong một Notebook duy nhất.
- Dữ liệu gốc, dữ liệu sạch, nhật ký lỗi, báo cáo kết quả, README và slide thuyết trình.
- Nhật ký sử dụng AI và bảng phân công đóng góp cá nhân.

5. Yêu cầu học máy chung

- Xây dựng một baseline đơn giản để làm mốc so sánh.
- Chia tập train/test trước khi học các tham số từ dữ liệu.
- Sử dụng Pipeline khi có bước mã hóa, chuẩn hóa hoặc điền thiếu.
- Không đánh giá mô hình trên chính dữ liệu huấn luyện.
- Phân tích ít nhất 10 trường hợp mô hình dự đoán sai hoặc gợi ý không phù hợp.
- Nêu rõ giới hạn dữ liệu, rủi ro thiên lệch và điều kiện không nên triển khai mô hình.

II. CHUYÊN ĐỀ ĐỂ CÁC NHÓM LỰA CHỌN

Sáu chuyên đề dưới đây có mức độ tương đương nhưng khác nhau về lĩnh vực và trọng tâm kỹ thuật. Mỗi nhóm lựa chọn một chuyên đề, sau đó thu hẹp phạm vi theo khả năng dữ liệu và năng lực của hai thành viên.

CHUYÊN ĐỀ 1. PHÂN TÍCH SẢN PHẨM VÀ ĐÁNH GIÁ

THƯƠNG MẠI ĐIỆN TỬ

Thu thập sản phẩm, theo dõi giá, phân tích review và xây dựng hệ thống gợi ý “đáng mua”

1. Bối cảnh và mục tiêu

Người mua thường phải so sánh nhiều sản phẩm có giá, mức giảm, lượt bán và đánh giá khác nhau. Nhóm xây dựng một quy trình thu thập dữ liệu của một ngành hàng cụ thể, chuẩn hóa thông tin, phân tích nội dung đánh giá và gợi ý sản phẩm phù hợp.

- Phân tích quan hệ giữa giá, mức giảm, lượt bán, điểm sao và nội dung đánh giá.
- Phát hiện sản phẩm trùng, tên sản phẩm nhiễu, giá bất thường và review không hợp lệ.
- Phân loại sản phẩm tốt/cần thận trọng hoặc dự đoán điểm đánh giá.
- Phân cụm sản phẩm theo mức giá, độ phổ biến và chất lượng cảm nhận.

2. Phạm vi lựa chọn

- Chọn đúng một mặt hàng: tai nghe, bàn phím, laptop, đồ gia dụng, mỹ phẩm hoặc một nhóm tương đương.
- Chỉ chọn một nền tảng hoặc một tập dữ liệu snapshot được phép sử dụng.
- Có thể thu thập ở 02-03 thời điểm để phân tích biến động giá.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Sản phẩm	Tối thiểu 800; khuyến khích 1.000-2.000
Đánh giá	Tối thiểu 5.000; khuyến khích 8.000 trở lên
Thương hiệu/người bán	Tối thiểu 5 nhóm
Thời gian	01 thời điểm; khuyến khích theo dõi 7-14 ngày

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
products	product_id, product_name, brand, category, seller_id, original_price, selling_price, discount_percent, rating_average, review_count, sold_count, collected_at
reviews	review_id, product_id, rating, review_text, review_date, helpful_count, has_image, variant, sentiment_label

Bảng/Thực thể	Thuộc tính chính
price_history	product_id, collected_at, original_price, selling_price, stock_status

5. Câu hỏi nghiên cứu và phân tích

1. Giá và mức giảm khác nhau như thế nào giữa các thương hiệu?
2. Giảm giá cao có liên hệ với lượt bán hoặc số review không?
3. Điểm sao có phản ánh đúng sắc thái nội dung review không?
4. Những vấn đề nào thường xuất hiện trong đánh giá tiêu cực?
5. Sản phẩm nào có giá hoặc tỷ lệ review bất thường?
6. Có thể dự đoán sản phẩm “đáng mua” từ giá, lượt bán và review không?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và xử lý tập tin

- Xây dựng các lớp Product, Review, CollectionLog và ProductDataManager.
- Đọc/ghi CSV, JSON; phát hiện sản phẩm trùng; ghi lỗi và checkpoint.

6.2. Thu thập và làm sạch

- Đọc HTML/API hợp lệ hoặc snapshot; chuẩn hóa giá, tên thương hiệu, số lượt bán và ngày.
- Loại thông tin nhận diện người đánh giá; xử lý review rỗng, trùng và sai điểm sao.

6.3. NumPy, Pandas và EDA

- Tính trung bình, trung vị, độ lệch chuẩn, chuẩn hóa giá và phát hiện ngoại lệ.
- Merge sản phẩm-review, Groupby theo thương hiệu, Pivot theo thời gian; vẽ ít nhất 08 biểu đồ.

6.4. Học máy và gợi ý

- Baseline và ít nhất 02 mô hình phân lớp hoặc hồi quy.
- K-Means phân khúc sản phẩm; xây dựng điểm phù hợp theo ngân sách và nhu cầu.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDL	Chọn ngành hàng, câu hỏi nghiên cứu và thuộc tính.
2	Python nâng cao/OOP	Thiết kế lớp Product, Review và quản lý tập tin.
3	Thu thập/NumPy	Thu thập nguồn thứ hai, xử lý HTML/JSON, thống kê giá.
4	Pandas làm sạch	Chuẩn hóa giá, tên sản phẩm, thương hiệu và review.
5	Merge/Groupby/Pivot	Liên kết sản phẩm-review và tạo bảng tổng hợp.
6	EDA	Phân tích giá, lượt bán, điểm sao và sentiment.

Buổi	Nội dung học	Công việc của chuyên đề
7	Mô hình có giám sát	Baseline, phân lớp/hồi quy và phân tích sai số.
8	Phân cụm/hoàn thiện	K-Means, hệ gợi ý, báo cáo và thuyết trình.

8. Sản phẩm cuối cùng

- Bộ dữ liệu sản phẩm-review đã làm sạch và từ điển dữ liệu.
- Báo cáo ngành hàng, top sản phẩm, cảnh báo review tiêu cực và biến động giá.
- Mô hình dự đoán chất lượng hoặc điểm đánh giá.
- Chương trình nhập ngân sách/nhu cầu và trả về top 5 sản phẩm phù hợp.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	Thu thập dữ liệu, OOP, xử lý HTML/JSON, ghi lỗi và checkpoint.	Kiểm tra chéo dữ liệu sạch và kết quả mô hình.
Thành viên 2	Làm sạch review, EDA, sentiment, mô hình và hệ gợi ý.	Kiểm tra chéo logic thu thập và từ điển dữ liệu.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Anti-bot, infinite scroll hoặc trang thay đổi cấu trúc	Dùng snapshot HTML/JSON, dữ liệu công khai được phép hoặc dữ liệu giảng viên cung cấp.
Review quá nhiều hoặc không cân bằng	Lấy mẫu theo sản phẩm, thương hiệu và mức sao; báo cáo chiến lược lấy mẫu.
Tên sản phẩm rất nhiều	Thiết kế quy tắc chuẩn hóa, từ điển thương hiệu và kiểm tra thủ công một mẫu.

CHUYÊN ĐỀ 2. PHÂN TÍCH SẮC THÁI TRUYỀN THÔNG

THEO CHỦ ĐỀ THỜI SỰ

Thu thập bài viết/bình luận, theo dõi xu hướng và xây dựng mô hình phân loại cảm xúc tiếng Việt

1. Bối cảnh và mục tiêu

Một chủ đề thời sự có thể được phản ánh khác nhau giữa các nguồn và thay đổi nhanh theo thời gian. Nhóm xây dựng pipeline thu thập, làm sạch văn bản, gắn nhãn, phân tích xu hướng và phân loại cảm xúc.

- Theo dõi mức độ quan tâm và sắc thái theo thời gian.
- So sánh khác biệt giữa các nguồn/kênh.
- Xây dựng bộ dữ liệu cảm xúc tiếng Việt có hướng dẫn gắn nhãn.
- Phân loại cảm xúc và phân cụm chủ đề nhỏ.

2. Phạm vi lựa chọn

- Chọn một chủ đề: AI trong giáo dục, tuyển sinh, môi trường, an toàn thực phẩm, du lịch, thể thao hoặc công nghệ.
- Giới hạn khoảng thời gian 30-90 ngày và từ 5 nguồn trở lên.
- Ưu tiên RSS, nguồn tin công khai, API hợp lệ hoặc dữ liệu giảng viên cung cấp; không yêu cầu cào toàn bộ TikTok/Facebook.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Văn bản	Tối thiểu 2.000 bài viết/tiêu đề/bình luận
Nguồn	Tối thiểu 5 nguồn hoặc kênh
Nhãn cảm xúc	Tối thiểu 500 văn bản gắn nhãn
Khoảng thời gian	Tối thiểu 30 ngày

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
posts	post_id, platform, source_name, published_at, title, content, keyword, url, like_count, comment_count, share_count

Bảng/Thực thể	Thuộc tính chính
comments	comment_id, post_id, comment_text, created_at, like_count, sentiment, topic
annotation_log	record_id, annotator_1, annotator_2, final_label, disagreement_note

5. Câu hỏi nghiên cứu và phân tích

- Mức độ quan tâm đến chủ đề thay đổi theo thời gian như thế nào?
- Nguồn nào đăng nhiều nội dung và có sắc thái khác biệt nhất?
- Sự kiện nào làm tỷ lệ tích cực hoặc tiêu cực thay đổi mạnh?
- Từ khóa nào thường xuất hiện trong văn bản tiêu cực?
- Tiêu đề báo và bình luận độc giả có cùng sắc thái không?
- Mô hình thường nhầm lẫn loại câu nào?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và thu thập

- Xây dựng NewsPost, SocialComment, DataCollector, TextPreprocessor và CollectionManager.
- Lưu dữ liệu thô/sạch riêng, checkpoint và nhật ký lỗi nguồn.

6.2. Làm sạch và gắn nhãn

- Xử lý HTML, URL, hashtag, emoji, khoảng trắng, bản ghi trùng và văn bản rỗng.
- Hai thành viên cùng gắn nhãn ít nhất 100 mẫu để thống nhất hướng dẫn.

6.3. Pandas, EDA và chuỗi thời gian

- Groupby theo ngày/nguồn, Pivot cảm xúc theo thời gian; phân tích độ dài và tương tác.
- Vẽ xu hướng, phân bố cảm xúc, top từ khóa và ma trận nhầm lẫn.

6.4. Học máy và phân cụm

- Baseline theo lớp phổ biến hoặc luật từ khóa.
- TF-IDF + Logistic Regression/Naive Bayes; K-Means phân nhóm chủ đề.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDL	Chọn chủ đề, từ khóa, khoảng thời gian và đơn vị quan sát.
2	Python nâng cao/OOP	Thiết kế lớp văn bản, collector và file log.
3	Thu thập/NumPy	Đọc API/RSS/JSON, thống kê số bài theo thời gian.
4	Pandas làm sạch	Làm sạch text, trùng lặp và dữ liệu thiếu.
5	Merge/Groupby/Pivot	Ghép bài-bình luận, tổng hợp theo nguồn/ngày.

Buổi	Nội dung học	Công việc của chuyên đề
6	EDA	Xu hướng, từ khóa, tương tác và sentiment.
7	Phân lớp	TF-IDF, baseline, mô hình và đánh giá Macro-F1.
8	Phân cụm/hoàn thiện	K-Means chủ đề, dashboard và báo cáo.

8. Sản phẩm cuối cùng

- Bộ dữ liệu văn bản đã ẩn danh, hướng dẫn gắn nhãn và nhật ký bất đồng.
- Dashboard hoặc báo cáo xu hướng và tỷ lệ cảm xúc theo thời gian/nguồn.
- Mô hình dự đoán sentiment cho một câu mới.
- Danh sách các chủ đề nhỏ và bài viết tiêu biểu của từng cụm.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	Pipeline thu thập, OOP, metadata, checkpoint và xử lý nguồn.	Kiểm tra chéo quy trình gắn nhãn và mô hình.
Thành viên 2	Làm sạch văn bản, gắn nhãn, EDA, TF-IDF và mô hình.	Kiểm tra chéo lỗi thu thập và dữ liệu trùng.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Nền tảng hạn chế API hoặc dữ liệu động	Dùng RSS, nguồn tin công khai, dữ liệu snapshot hoặc bộ dữ liệu giảng viên cung cấp.
Văn bản mất cân bằng cảm xúc	Lấy mẫu theo thời gian/nguồn/lớp và dùng Macro-F1 thay vì chỉ Accuracy.
Nhãn chủ quan	Viết hướng dẫn gắn nhãn, gắn nhãn chéo và lưu lý do bất đồng.

CHUYÊN ĐỀ 3. PHÂN TÍCH VÀ GỢI Ý BẤT ĐỘNG SẢN

Làm sạch giá - diện tích - địa điểm, dự đoán giá và gợi ý tin phù hợp theo ngân sách

1. Bối cảnh và mục tiêu

Tin bất động sản thường có mô tả dài, cách ghi giá và diện tích không thống nhất, địa danh viết tắt và nhiều tin đăng trùng. Nhóm xây dựng pipeline chuẩn hóa, phân tích giá, dự đoán và gợi ý tin phù hợp.

- Chuẩn hóa giá, diện tích, giá trên mét vuông, địa điểm và thuộc tính mô tả.
- Phát hiện tin trùng và ngoại lệ.
- Dự đoán tổng giá hoặc giá trên mét vuông.
- Phân khúc bất động sản và gợi ý theo nhu cầu.

2. Phạm vi lựa chọn

- Chọn một thành phố, 2-3 quận/huyện hoặc một loại hình như căn hộ chung cư.
- Không thu thập tên, số điện thoại hoặc địa chỉ nhà quá chi tiết.
- Dùng dữ liệu công khai được phép, API hợp lệ hoặc snapshot do giảng viên cung cấp.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Tin đăng	Tối thiểu 1.000; khuyến khích 2.000-5.000
Thuộc tính	Tối thiểu 15
Khu vực	Ít nhất 3 quận/huyện hoặc 5 phường/xã
Dữ liệu văn bản	Có tiêu đề và mô tả để làm sạch sâu

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
listings	listing_id, title, property_type, province, district, ward, area_m2, total_price, price_per_m2, bedrooms, bathrooms, legal_status, furniture_status, posted_at, description
locations	district, ward, latitude, longitude, location_accuracy
cleaning_log	listing_id, issue_type, original_value, cleaned_value, decision

5. Câu hỏi nghiên cứu và phân tích

13. Khu vực nào có giá trên mét vuông cao nhất?
14. Diện tích và số phòng ảnh hưởng như thế nào đến tổng giá?
15. Pháp lý, nội thất và loại hình có liên hệ với giá không?
16. Tin nào có giá/diện tích bất thường hoặc có khả năng trùng?
17. Mô hình dự đoán giá đạt sai số bao nhiêu?
18. Top 5 tin nào phù hợp với từng hồ sơ ngân sách?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và dữ liệu

- Xây dựng PropertyListing, Location, PropertyDataManager và RecommendationEngine.
- Đọc/ghi CSV/JSON, ghi cleaning log và error log.

6.2. Làm sạch sâu

- Chuẩn hóa “3,5 tỷ”, “3500 triệu”, “75 m2”, giá thỏa thuận và địa danh viết tắt.
- Tạo giá trên mét vuông, phát hiện tin trùng theo mã và độ tương đồng nội dung.

6.3. EDA và mô hình

- Groupby/Pivot theo khu vực, loại hình và pháp lý; bản đồ mức quận nếu dữ liệu cho phép.
- Dummy Regressor, Linear Regression, Decision Tree Regressor; đánh giá MAE, RMSE, R2.

6.4. Phân cụm và gợi ý

- K-Means phân khúc theo giá, diện tích, vị trí và tiện ích.
- Gợi ý top 5 theo ngân sách, khu vực, diện tích, số phòng và pháp lý.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDL	Chọn khu vực/loại hình, mục tiêu và thuộc tính.
2	Python nâng cao/OOP	Thiết kế lớp tin đăng, địa điểm và gợi ý.
3	Thu thập/NumPy	Đọc HTML/JSON, chuẩn hóa số cơ bản, thống kê giá.
4	Pandas làm sạch	Giá, diện tích, địa danh, mô tả và tin trùng.
5	Merge/Groupby/Pivot	Ghép vị trí, tổng hợp theo quận/loại hình.
6	EDA	Giá, diện tích, pháp lý, ngoại lệ và phân bố khu vực.
7	Hồi quy	Baseline, Linear/Tree và phân tích sai số.
8	Phân cụm/hoàn thiện	Phân khúc, hệ gợi ý và báo cáo.

8. Sản phẩm cuối cùng

- Dữ liệu tin đăng đã chuẩn hóa và danh sách các quy tắc làm sạch.
- Báo cáo giá theo khu vực, loại hình và thuộc tính.
- Mô hình dự đoán giá và phân tích 10 trường hợp sai số lớn.
- Chương trình nhập hồ sơ nhu cầu và trả về top 5 tin phù hợp kèm điểm phù hợp.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	Thu thập, OOP, chuẩn hóa giá/diện tích/địa điểm và phát hiện trùng.	Kiểm tra chéo mô hình và các hồ sơ gợi ý.
Thành viên 2	EDA, mô hình hồi quy, phân cụm và hệ gợi ý.	Kiểm tra chéo quy tắc làm sạch và nhật ký lỗi.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Giá “thỏa thuận” hoặc nhiều đơn vị	Tách thành trường trạng thái, chỉ dự đoán trên bản ghi có giá hợp lệ.
Thiếu tọa độ	Dùng cấp quận/huyện; không suy đoán tọa độ nếu không có nguồn rõ ràng.
Tin đăng trùng hoặc tái đăng	Kết hợp mã, tiêu đề, diện tích, giá và tương đồng mô tả để đánh dấu.

CHUYÊN ĐỀ 4. PHÂN TÍCH THỊ TRƯỜNG VÀ GỢI Ý VIỆC LÀM

Chuẩn hóa mức lương - kỹ năng, dự đoán lương và gợi ý tin tuyển dụng theo hồ sơ ứng viên

1. Bối cảnh và mục tiêu

Tin tuyển dụng có tên vị trí, mức lương, kinh nghiệm và kỹ năng được mô tả không thống nhất. Nhóm xây dựng pipeline chuẩn hóa, phân tích xu hướng, dự đoán lương và gợi ý việc làm.

- Xác định kỹ năng phổ biến và chênh lệch lương theo vị trí, kinh nghiệm và thành phố.
- Chuẩn hóa mức lương và tên kỹ năng.
- Dự đoán lương trung bình hoặc phân loại nhóm lương.
- Phân cụm và gợi ý việc làm phù hợp với hồ sơ kỹ năng.

2. Phạm vi lựa chọn

- Chọn một nhóm nghề: lập trình, phân tích dữ liệu, marketing, kế toán, nhân sự, ngôn ngữ hoặc kỹ thuật.
- Không thu thập CV, email, số điện thoại hoặc dữ liệu cá nhân của ứng viên.
- Dùng nguồn công khai được phép, API/snapshot hợp lệ hoặc dữ liệu mô phỏng có kiểm soát.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Tin tuyển dụng	Tối thiểu 1.000; khuyến khích 2.000-5.000
Kỹ năng chuẩn hóa	Tối thiểu 20 kỹ năng
Thuộc tính	Tối thiểu 12
Khu vực/thành phố	Tối thiểu 3

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
job_postings	job_id, job_title, company_id, industry, city, experience_years, education_level, job_type, remote_option, salary_min, salary_max, posted_at, description
job_skills	job_id, skill_name, skill_group, required_level
companies	company_id, company_size, industry, city

5. Câu hỏi nghiên cứu và phân tích

19. Kỹ năng nào được yêu cầu nhiều nhất?
20. Mức lương thay đổi như thế nào theo kinh nghiệm, thành phố và hình thức làm việc?
21. Yêu cầu tiếng Anh có liên hệ với mức lương không?
22. Vị trí nào thường không công khai mức lương?
23. Mô hình dự đoán mức lương đạt sai số bao nhiêu?
24. Top công việc nào phù hợp với từng hồ sơ kỹ năng?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và thu thập

- Xây dựng JobPosting, Skill, JobDataManager và RecommendationEngine.
- Đọc HTML/JSON/CSV, phát hiện tin trùng, ghi lỗi và metadata nguồn.

6.2. Làm sạch văn bản và số

- Chuẩn hóa “10-15 triệu”, “tới 20 triệu”, “cạnh tranh”, lương tháng/năm và kinh nghiệm.
- Chuẩn hóa kỹ năng đồng nghĩa và tên vị trí tương đương.

6.3. EDA và mô hình

- Groupby/Pivot theo vị trí, thành phố, kinh nghiệm và kỹ năng.
- Baseline, Linear Regression, Decision Tree; hoặc phân lớp lương thấp/trung bình/cao.

6.4. Phân cụm và gợi ý

- K-Means phân nhóm công việc theo lương, kỹ năng, kinh nghiệm và remote.
- Gợi ý dựa trên độ tương đồng giữa hồ sơ ứng viên và tin tuyển dụng.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDH	Chọn nhóm nghề, mục tiêu và thuộc tính.
2	Python nâng cao/OOP	Thiết kế lớp tin việc làm, kỹ năng và gợi ý.
3	Thu thập/NumPy	Đọc nguồn thứ hai, chuẩn hóa lương cơ bản.
4	Pandas làm sạch	Tên vị trí, kỹ năng, kinh nghiệm, lương và trùng.
5	Merge/Groupby/Pivot	Ghép job-skills-company và tổng hợp.
6	EDA	Lương, kỹ năng, thành phố, remote và thời gian.
7	Mô hình	Baseline, hồi quy/phân lớp và phân tích lỗi.
8	Phân cụm/hoàn thiện	Nhóm việc làm, hệ gợi ý và báo cáo.

8. Sản phẩm cuối cùng

- Dữ liệu tuyển dụng đã chuẩn hóa và từ điển kỹ năng.
- Báo cáo thị trường việc làm theo vị trí, kỹ năng, địa điểm và mức lương.
- Mô hình dự đoán lương hoặc nhóm lương.
- Chương trình nhập kỹ năng/kinh nghiệm/thành phố và trả về top 5 việc làm phù hợp.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	Thu thập, OOP, chuẩn hóa lương/kinh nghiệm và dữ liệu nguồn.	Kiểm tra chéo hệ gợi ý và mô hình.
Thành viên 2	Chuẩn hóa kỹ năng, EDA, mô hình, phân cụm và gợi ý.	Kiểm tra chéo tính hợp lệ của dữ liệu và nhật ký lỗi.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Nhiều tin không công khai lương	Tách bài toán phân tích thiếu lương; chỉ huấn luyện hồi quy trên bản ghi hợp lệ.
Tên kỹ năng và vị trí không thống nhất	Xây dựng từ điển ánh xạ và lưu cả giá trị gốc lẫn giá trị chuẩn hóa.
Tin đăng lại	Dùng job_id, tiêu đề, công ty, ngày và tương đồng mô tả để đánh dấu.

CHUYÊN ĐỀ 5. PHÂN TÍCH KẾT QUẢ HỌC TẬP VÀ DỰ BÁO NGUY CƠ

Kết hợp điểm và hành vi học tập để phát hiện sớm sinh viên có nguy cơ không hoàn thành học phần

1. Bối cảnh và mục tiêu

Giảng viên cần phát hiện sớm sinh viên có nguy cơ không đạt để hỗ trợ kịp thời. Nhóm kết hợp dữ liệu điểm, chuyên cần và hoạt động học tập, xây dựng mô hình phân lớp và phân nhóm hành vi.

- Phân tích các yếu tố liên quan đến kết quả học tập.
- Dự đoán đạt/không đạt hoặc điểm cuối kỳ.
- Phân nhóm sinh viên theo hành vi học tập.
- Xuất danh sách ưu tiên hỗ trợ và giải thích lý do.

2. Phạm vi lựa chọn

- Dữ liệu phải được ẩn danh; không sử dụng họ tên, số điện thoại hoặc thông tin nhạy cảm.
- Có thể kết hợp dữ liệu điểm CSV với dữ liệu hoạt động LMS dạng JSON.
- Có thể dùng dữ liệu mô phỏng nếu không có dữ liệu thật.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Sinh viên-học phần	Tối thiểu 1.000 bản ghi; có thể ghép nhiều lớp/học kỳ
Lớp/học phần	Tối thiểu 5 lớp hoặc 3 học phần
Thuộc tính	Tối thiểu 12
Tỷ lệ không đạt	Nên có tối thiểu 10% để đánh giá phân lớp

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
students	student_id, class_name, major, previous_gpa
learning_records	student_id, course_id, attendance_rate, assignment_average, midterm_score, late_submissions, lms_logins, online_hours, discussion_posts, final_score, pass_status
support_log	student_id, risk_score, risk_group, suggested_action, reviewed_by

5. Câu hỏi nghiên cứu và phân tích

25. Yếu tố nào liên hệ mạnh nhất với kết quả học tập?
26. Chuyên cần thấp làm nguy cơ không đạt tăng như thế nào?
27. Nộp bài muộn và hoạt động LMS có liên hệ với điểm không?
28. Mô hình có thể phát hiện sinh viên nguy cơ với Recall bao nhiêu?
29. Những nhóm hành vi học tập nào tồn tại?
30. Những trường hợp nào mô hình thường dự đoán sai?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và quản lý dữ liệu

- Xây dựng Student, CourseActivity, LearningRecord và StudentManager.
- Kiểm tra điểm 0-10, trùng mã trong học phần, ghi lỗi và báo cáo TXT/CSV.

6.2. NumPy và Pandas

- Tính điểm tổng kết bằng vector, chuẩn hóa biến và mô phỏng dữ liệu thiếu.
- Merge điểm-LMS, xử lý thiếu/trùng, Groupby/Pivot theo lớp và học phần.

6.3. EDA

- Phân phối điểm, tỷ lệ đạt, chuyên cần, nộp muộn, hoạt động LMS và tương quan.

6.4. Học máy

- Baseline, Logistic Regression, Decision Tree/KNN; đánh giá Recall, F1 và Confusion Matrix.
- K-Means phân nhóm hành vi học tập; tùy chọn hồi quy điểm cuối kỳ.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDL	Xác định bài toán, biến đầu vào/đầu ra và rủi ro đạo đức.
2	Python nâng cao/OOP	Thiết kế Student, LearningRecord và file log.
3	Thu thập/NumPy	Kết hợp điểm/LMS, tính toán vector.
4	Pandas làm sạch	Thiếu, trùng, miền điểm và chuẩn hóa lớp.
5	Merge/Groupby/Pivot	Ghép nguồn, thống kê theo lớp/học phần.
6	EDA	Chuyên cần, điểm, LMS và nhóm nguy cơ.
7	Phân lớp/hồi quy	Baseline, mô hình và phân tích sai số.
8	Phân cụm/hoàn thiện	Nhóm hành vi, danh sách hỗ trợ và báo cáo.

8. Sản phẩm cuối cùng

- Bộ dữ liệu ẩn danh và báo cáo chất lượng dữ liệu.
- Mô hình dự đoán nguy cơ và danh sách sinh viên cần hỗ trợ.
- Phân nhóm hành vi học tập và gợi ý can thiệp.
- Báo cáo giải thích giới hạn, rủi ro thiên lệch và cách sử dụng có trách nhiệm.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	OOP, File I/O, làm sạch dữ liệu điểm/LMS và NumPy.	Kiểm tra chéo EDA, mô hình và danh sách nguy cơ.
Thành viên 2	EDA, mô hình phân lớp/hồi quy, phân cụm và phân tích lỗi.	Kiểm tra chéo dữ liệu sạch và quy tắc tính điểm.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Dữ liệu cá nhân và quyết định nhạy cảm	Ẩn danh; chỉ dùng mô hình hỗ trợ, không tự động đưa ra quyết định học vụ.
Lớp không đạt quá ít	Dùng stratified split, Recall/Macro-F1 và báo cáo mất cân bằng.
Rò rỉ dữ liệu	Không dùng biến chỉ xuất hiện sau thời điểm cần dự báo; chia train/test trước tiên xử lý.

CHUYÊN ĐỀ 6. PHÂN TÍCH BÁN HÀNG, QUẢN LÝ TỒN KHO VÀ PHÂN NHÓM KHÁCH HÀNG

Kết hợp OOP quản lý kho, phân tích giao dịch, RFM và mô hình dự đoán giá trị đơn hàng

1. Bối cảnh và mục tiêu

Một cửa hàng cần quản lý sản phẩm, nhập-xuất kho, theo dõi doanh thu và nhận diện nhóm khách hàng. Nhóm xây dựng hệ thống vừa có chức năng nghiệp vụ, vừa có phân tích khoa học dữ liệu và mô hình học máy.

- Xây dựng hệ thống nhập, xuất, điều chỉnh tồn kho có nhật ký.
- Phân tích doanh thu, sản phẩm bán chạy và cặp sản phẩm thường mua cùng nhau.
- Phân nhóm khách hàng theo RFM.
- Dự đoán giá trị đơn hàng hoặc nguy cơ xuống dưới mức cảnh báo.

2. Phạm vi lựa chọn

- Sử dụng bộ dữ liệu sản phẩm và giao dịch do giảng viên cung cấp, sau đó mở rộng thành dữ liệu bán hàng hoàn chỉnh.
- Có các bảng sản phẩm, khách hàng, đơn hàng, chi tiết đơn và giao dịch kho.
- Không sử dụng dữ liệu nhận diện khách hàng thật.

Lưu ý: Dự án không yêu cầu “cào toàn bộ nền tảng”. Nhóm phải xác định một phạm vi có kiểm soát, có thể tái lập, tuân thủ điều khoản sử dụng và có phương án dữ liệu dự phòng.

3. Quy mô dữ liệu tối thiểu

Thành phần	Yêu cầu tối thiểu
Đơn hàng	Tối thiểu 1.000
Dòng chi tiết đơn	Tối thiểu 3.000
Khách hàng	Tối thiểu 200
Sản phẩm	Tối thiểu 50

4. Cấu trúc dữ liệu đề nghị

Bảng/Thực thể	Thuộc tính chính
products	product_id, product_name, category, unit_price, initial_quantity, reorder_level
customers	customer_id, city, customer_type, join_date
orders	order_id, customer_id, order_date, payment_method, sales_channel, discount

Bảng/Thực thể	Thuộc tính chính
order_details	order_id, product_id, quantity, selling_price
inventory_transactions	transaction_id, timestamp, transaction_type, product_id, quantity, performed_by, status

5. Câu hỏi nghiên cứu và phân tích

31. Danh mục và kênh bán nào tạo doanh thu lớn nhất?
32. Sản phẩm nào bán chạy, bán chậm hoặc thường mua cùng nhau?
33. Thời điểm nào có doanh thu cao nhất?
34. Khách hàng có thể chia thành những nhóm RFM nào?
35. Có thể dự đoán giá trị đơn hàng không?
36. Sản phẩm nào có nguy cơ xuống dưới mức cảnh báo?

6. Nội dung kỹ thuật bắt buộc

6.1. Python, OOP và nghiệp vụ kho

- Xây dựng Product, Customer, Order, OrderItem, InventoryTransaction, InventoryManager và SalesManager.
- Từ chối giao dịch làm tồn kho âm; ghi inventory_log.csv và error_log.txt.

6.2. Cấu trúc dữ liệu và File I/O

- Phân tích giao dịch dictionary lồng nhau; tính doanh thu, chỉ tiêu khách hàng và cặp sản phẩm.
- Đọc/ghi CSV/JSON và xử lý tập tin thiếu hoặc dòng lỗi.

6.3. NumPy, Pandas và EDA

- Tạo ma trận doanh thu, tính theo axis, giá trị tồn kho và chuẩn hóa.
- Merge nhiều bảng, Groupby/Pivot theo tháng, danh mục, thành phố và kênh bán.

6.4. Học máy và phân cụm

- Dummy/Linear/Decision Tree dự đoán giá trị đơn hàng.
- Logistic/Tree dự đoán cảnh báo tồn kho; K-Means phân nhóm RFM.

7. Lộ trình thực hiện theo 8 buổi

Buổi	Nội dung học	Công việc của chuyên đề
1	Tổng quan KHDL	Xác định câu hỏi, bảng dữ liệu và chỉ số kinh doanh.
2	Python nâng cao/OOP	Xây dựng lớp kho, đơn hàng, khách hàng và nhật ký.
3	Thu thập/NumPy	Đọc CSV/JSON lồng nhau, ma trận doanh thu và tồn kho.
4	Pandas làm sạch	Kiểm tra mã, số lượng, giá, ngày và giao dịch lỗi.

Buổi	Nội dung học	Công việc của chuyên đề
5	Merge/Groupby/Pivot	Ghép 5 bảng và tạo báo cáo tổng hợp.
6	EDA	Doanh thu, sản phẩm, khách hàng, tồn kho và mùa vụ.
7	Mô hình	Dự đoán giá trị đơn hàng/cảnh báo tồn kho.
8	Phân cụm/hoàn thiện	RFM, K-Means, hệ thống báo cáo và bảo vệ.

8. Sản phẩm cuối cùng

- Chương trình quản lý kho có nhật ký và xử lý lỗi.
- Báo cáo doanh thu, tồn kho, sản phẩm bán chạy và cập sản phẩm.
- Phân nhóm khách hàng theo RFM và mô tả chiến lược cho từng nhóm.
- Mô hình dự đoán giá trị đơn hàng hoặc nguy cơ tồn kho thấp.

9. Gợi ý phân công hai thành viên

Thành viên	Nhiệm vụ chính	Nhiệm vụ kiểm tra chéo
Thành viên 1	OOP quản lý kho, File I/O, làm sạch và merge dữ liệu.	Kiểm tra chéo mô hình, RFM và báo cáo EDA.
Thành viên 2	EDA bán hàng, RFM, mô hình và phân cụm.	Kiểm tra chéo nghiệp vụ kho và nhật ký giao dịch.

10. Rủi ro và phương án dự phòng

Rủi ro	Biện pháp xử lý
Tồn kho bị cập nhật sai do thứ tự giao dịch	Sắp xếp theo thời gian, kiểm tra transaction_id và lưu trạng thái trước/sau.
Merge làm tăng số dòng bất thường	Kiểm tra khóa, cardinality và số dòng trước/sau merge.
RFM phụ thuộc ngày chốt	Cố định ngày tham chiếu và ghi rõ trong báo cáo.

III. SO SÁNH VÀ KHUYẾN NGHỊ LỰA CHỌN CHUYÊN ĐỀ

Chuyên đề	Dữ liệu chính	Thử thách nổi bật	Bài toán chính
1. Thương mại điện tử	Sản phẩm, giá, review	Thu thập và liên kết review	Phân loại chất lượng/hồi quy rating
2. Truyền thông	Bài viết, bình luận	Làm sạch và gắn nhãn văn bản	Sentiment + phân cụm chủ đề
3. Bất động sản	Tin đăng, giá, vị trí	Chuẩn hóa giá/diện tích/tin trùng	Hồi quy giá + gợi ý
4. Việc làm	Tin tuyển dụng, kỹ năng	Chuẩn hóa lương và kỹ năng	Hồi quy/phân lớp lương + gợi ý
5. Giáo dục	Điểm và hành vi học	Rò rỉ dữ liệu và quyền riêng tư	Phân lớp nguy cơ + phân cụm
6. Bán hàng/kho	Giao dịch, tồn kho, khách hàng	Nghiệp vụ kho và merge nhiều bảng	Hồi quy + RFM/K-Means

Khuyến nghị

- Nhóm mạnh về lập trình thu thập dữ liệu và xử lý nhiều trang: chọn Chuyên đề 1.
- Nhóm mạnh về tiếng Việt, NLP và phân tích nội dung: chọn Chuyên đề 2.
- Nhóm muốn cân bằng dữ liệu bảng, hồi quy và hệ gợi ý: chọn Chuyên đề 3 hoặc 4.
- Nhóm muốn tập trung vào phân lớp, đánh giá mô hình và dữ liệu giáo dục: chọn Chuyên đề 5.
- Nhóm muốn thực hành OOP, File I/O, Merge, RFM và nghiệp vụ thực tế: chọn Chuyên đề 6.

IV. CÁC MỐC KIỂM TRA THEO 08 BUỔI

Mốc	Sản phẩm phải nộp
Sau Buổi 1	Tên đề tài, phạm vi, 5 câu hỏi nghiên cứu, sơ đồ dữ liệu, phân công ban đầu.
Sau Buổi 2	Thiết kế lớp, mã OOP bước đầu, đọc/ghi dữ liệu, nhật ký lỗi mẫu.
Sau Buổi 3	Hai nguồn dữ liệu, Notebook thu thập, từ điển dữ liệu và thống kê NumPy.
Sau Buổi 4	Dữ liệu sạch, báo cáo thiếu/trùng/sai kiểu và quy tắc làm sạch.
Sau Buổi 5	Dữ liệu đã merge, kiểm tra khóa, 5 bảng Groupby/Pivot.
Sau Buổi 6	Notebook EDA, ít nhất 8 biểu đồ và 5 phát hiện.
Sau Buổi 7	Baseline, ít nhất 2 mô hình, bảng chỉ số và 10 trường hợp sai.
Kết thúc Buổi 8	Phân cụm/gợi ý, báo cáo hoàn chỉnh, slide và mã nguồn chạy được.

V. SẢN PHẨM NỘP, THANG ĐIỂM VÀ QUY ĐỊNH SỬ DỤNG AI

1. Danh mục sản phẩm nộp

- Thư mục data/raw và data/processed.

- Tối thiểu 04 Notebook theo quy trình dự án.
- Mã nguồn Python chia thành mô-đun/lớp rõ ràng.
- README hướng dẫn cài đặt và chạy lại dự án.
- Báo cáo 20-30 trang và slide thuyết trình.
- Nhật ký lỗi, nhật ký sử dụng AI và bảng đóng góp cá nhân.

2. Thang điểm đề xuất

Thành phần	Điểm
Xác định bài toán và thiết kế dữ liệu	8
Thu thập dữ liệu và ghi nguồn	8
Python, OOP và xử lý tập tin	12
NumPy	8
Pandas, làm sạch và ghép dữ liệu	14
EDA và trực quan hóa	12
Baseline và mô hình học máy	16
Đánh giá và phân tích lỗi	8
Báo cáo và khả năng tái lập	6
Thuyết trình và phản biện	5
Minh chứng đóng góp cá nhân	3
Tổng cộng	100

3. Điều kiện tối thiểu để được chấm đạt

- Có dữ liệu gốc và dữ liệu đã làm sạch.
- Mã nguồn chạy được từ đầu đến cuối.
- Có baseline và đánh giá trên tập test.
- Có phân công và minh chứng đóng góp của từng thành viên.
- Giải thích được mã nguồn và kết quả do AI hỗ trợ.
- Không vi phạm quyền riêng tư hoặc điều khoản sử dụng nguồn dữ liệu.

4. Quy định sử dụng AI

Sinh viên được sử dụng AI để học khái niệm, giải thích lỗi, gợi ý test case, rà soát mã, gợi ý biểu đồ và phản biện kết quả. Mỗi nhóm phải lưu prompt, đầu ra đã dùng, cách kiểm chứng và phản chỉnh sửa của nhóm. Không chấp nhận mã nguồn hoặc báo cáo mà sinh viên không giải thích được.

Ngày	Công cụ	Prompt	Kết quả sử dụng	Cách kiểm tra/điều chỉnh
...	...	...	...	...
...	...	...	...	...

5. Yêu cầu đóng góp cá nhân

- Mỗi thành viên phải có ít nhất một lớp Python do mình phụ trách.
- Mỗi thành viên phải thực hiện ít nhất một phần làm sạch dữ liệu và hai biểu đồ.
- Mỗi thành viên phải tham gia ít nhất một mô hình hoặc một phần đánh giá mô hình.
- Mỗi thành viên trình bày tối thiểu 7 phút và trả lời câu hỏi về phần mình phụ trách.
- Không chia công việc theo kiểu một người viết toàn bộ mã, người còn lại chỉ viết báo cáo.