

PHÂN TÍCH THỊ TRƯỜNG VIỆC LÀM IT & GỢI Ý ỨNG VIÊN BẰNG MACHINE LEARNING

GIỚI THIỆU

Chuyên đề 4 — Lập trình cho Khoa học Dữ liệu

Học viên: **Nguyễn Minh Tan** — GVHD: **GS.TS. Nguyễn Duy Hàm**

Tháng 8 năm 2026

2. NỘI DUNG TRÌNH BÀY

GIỚI THIỆU

Lộ trình trình bày được chia thành 5 phần chính, từ giới thiệu đề tài đến kết luận và hướng phát triển.

PHẦN 1 – GIỚI THIỆU & MỤC TIÊU

Slide 3-4

PHẦN 2 – PHƯƠNG PHÁP XỬ LÝ DỮ LIỆU

Slide 5-9

PHẦN 3 – PHÂN TÍCH KHÁM PHÁ (EDA)

Slide 10-12

PHẦN 4 – KẾT QUẢ MÔ HÌNH ML

Slide 13-20

PHẦN 5 – KẾT LUẬN & HƯỚNG PHÁT TRIỂN

Slide 21-23

3. Giới thiệu bài toán

GIỚI THIỆU

 **Thị trường IT Việt Nam** đang phát triển nhanh, nhu cầu tuyển dụng tập trung tại **Hà Nội, TP.HCM** và **Đà Nẵng**.

 Tin tuyển dụng phân tán trên nhiều nền tảng với định dạng tự do, khiến ứng viên khó so sánh **lương** và **kỹ năng** giữa các nguồn.

 Bốn nền tảng lớn (**Itviec, Glints, TopCV, Careerviet**) đăng tin theo các dạng khác nhau nên dữ liệu thu về không đồng nhất.

Mục tiêu của đề tài

 Thu thập tự động tin tuyển dụng IT từ **4 nguồn** bằng **Crawler v2**; làm sạch và chuẩn hóa **lương, kỹ năng, kinh nghiệm** về cùng một định dạng.

 Dự báo mức lương thị trường bằng **4 mô hình ML** và **K-Means**, rồi gợi ý việc làm phù hợp với hồ sơ (**Content-based**).

1.193

tin tuyển dụng

4

nguồn dữ liệu

44

thuộc tính

56%

tin ẩn lương

4. Câu hỏi nghiên cứu RQ1-RQ5

PHƯƠNG PHÁP

 Câu hỏi	Phương pháp
RQ1: Kỹ năng nào được yêu cầu nhiều nhất?	EDA — top skills
RQ2: Lương biến động theo kinh nghiệm, thành phố?	EDA — groupby, boxplot
RQ3: Có thể dự báo mức lương không, sai số bao nhiêu?	ML — RMSE, MAE, R²
RQ4: Thị trường phân khúc thành những nhóm nào?	K-Means — silhouette
RQ5: Việc nào phù hợp với hồ sơ kỹ năng?	Content-based — cosine

Insight

Các câu hỏi được sắp theo 3 lớp: **khám phá dữ liệu, mô hình hoá và gợi ý việc làm.**

ML metrics

Nhấn mạnh các chỉ số chính: **RMSE, R² và Silhouette Score.**

Data pipeline

Từ EDA đến clustering và content-based matching để trả lời toàn bộ RQ1-RQ5.

5. Kiến trúc hệ thống — Pipeline end-to-end

PHƯƠNG PHÁP

Thu thập & làm sạch dữ liệu

- **Crawler v2** xoay vòng 3 User-Agent, giới hạn tốc độ 1–3 giây, chạy 22 từ khóa trên 4 nguồn, thu về **1.193 tin**
- Trích lọc theo 4 kỹ thuật (**JSON-LD**, **__NEXT_DATA__**, **HTML**, **API**) rồi lưu dạng raw CSV + JSON kèm siêu dữ liệu nguồn
- **SalaryParser** đọc 8 cấu trúc lương (**56%** tin ẩn lương), **SkillNormalizer** gộp 188 quy tắc thành **45** kỹ năng chuẩn
- **ExperienceNormalizer** gán 5 bậc kinh nghiệm từ entry đến lead; **Deduplicator** loại **70** bản ghi trùng qua 4 pha kiểm tra

Feature engineering & mô hình

- **ColumnTransformer** xử lý 3 nhóm đặc trưng — **numeric** (trung vị + chuẩn hóa), **categorical** (OneHot), **ordinal**
- Loại bỏ cột thô, mục tiêu là **salary_mid** tính bằng triệu VND mỗi tháng
- Hồi quy giảm **RMSE** từ **8.97** xuống **4.17** (Linear) rồi **0.60** (Decision Tree)
- **K-Means** với **k = 10** đạt **Silhouette 0.38**; cosine similarity gợi ý **Top-3** việc phù hợp cho hồ sơ

💡 **Insight:** Pipeline được tối ưu từ thu thập → chuẩn hóa → mô hình hóa → gợi ý việc làm, giúp dữ liệu sạch hơn và dự báo chính xác hơn.

6. Crawler v2 — Thu thập dữ liệu

PHƯƠNG PHÁP

Thu thập & kiểm soát truy cập

- **Crawler** chạy qua từng nguồn và từ khóa (**22 từ khóa**), dừng khi đủ số tin tối thiểu, lịch sử ghi vào `crawl_history.json`
- **HttpClient (httpx)** bật xác thực SSL, tự động theo redirect và timeout **20 giây** để hạn chế lỗi kết nối bị chặn
- Xoay vòng **3 User-Agent**, giới hạn tốc độ **1-3 giây**, thử lại khi máy chủ trả **HTTP 429**
- Nhận diện trang bị chặn qua **BLOCKED_MARKERS** (`captcha`, `cf-challenge`)

Trích xuất & lưu trữ dữ liệu

- **4 kỹ thuật** trích xuất dữ liệu: **JSON-LD Parsing**, **__NEXT_DATA__**, **HTML Parsing** bằng BeautifulSoup, **API JSON**
- **JSON-LD Parsing**: đọc dữ liệu nhúng trong thẻ script `application/ld+json`
- **__NEXT_DATA__**: lấy JSON state của trang Next.js
- Lưu dữ liệu thô dạng **CSV + JSON** theo từng nguồn vào `data/raw/`, kèm log siêu metadata

7. Làm sạch & Chuẩn hóa dữ liệu

PHƯƠNG PHÁP

Vấn đề dữ liệu gốc

- **Lương:** 56% tin ẩn mức lương; còn lại viết dưới 8 dạng khác nhau
- **Kỹ năng:** Một kỹ năng có nhiều tên gọi gây nhiễu
- **Kinh nghiệm:** Mô tả tự do không có cấu trúc đồng nhất
- **Trùng lặp:** Cùng một tin được đăng lại trên nhiều nguồn hoặc nhiều ngày

Cách xử lý


- **SalaryParser:** 6 regex nhận diện 8 cấu trúc; USD→VND ×25.000; lương năm ×12
- **SkillNormalizer:** 188 quy tắc đồng nghĩa → 45 kỹ năng chuẩn; fuzzy matching >0.8
- **ExperienceNormalizer:** 6 regex TV/EN → 5 bậc (entry → lead); gán -1 cho giá trị thiếu
- **Deduplicator:** 4 pha (job_id, title+company, fuzzy title, fuzzy desc) → loại 70 bản ghi trùng

 Tập trung chuẩn hóa các trường nhiễu cao để dữ liệu sạch hơn, giảm sai lệch cho các bước phân tích tiếp theo.

8. Làm sạch — Chart dữ liệu thực tế


PHƯƠNG PHÁP

Tỷ lệ giá trị thiếu theo cột



salary_max và **min_experience** thiếu nhiều nhất do tin ẩn lương và mô tả tự do.

Phân bố số năm kinh nghiệm



Định ở **1-3 năm**, phần lớn tin tuyển dụng thuộc cấp độ **Junior** và **Mid-level**.



Insight: Sự thiếu hụt dữ liệu ở lương và kinh nghiệm là động lực chính để xây dựng **SalaryParser** và **ExperienceNormalizer**, nhằm tạo ra tập dữ liệu chuẩn cho ML.

8. Feature Engineering

PHƯƠNG PHÁP

3 nhóm đặc trưng trong ColumnTransformer [3]

- **Numeric** (`experience_years`): điền giá trị thiếu bằng trung vị rồi chuẩn hóa
- **Categorical** (`city`, `job_type`, `remote_option`, `education_level`, `industry`, `company_size`): điền "Unknown" khi thiếu, OneHotEncoder bỏ qua giá trị mới lạ
- **Ordinal** (`experience_bin` từ entry đến lead): giữ thứ tự qua OrdinalEncoder, giá trị thiếu gán -1

- Loại cột thô (`job_id`, `description`, `source_url`...); ColumnTransformer dùng `remainder="drop"`
- Chia dữ liệu **80/20** và đánh giá **5-fold cross-validation** để ước lượng độ ổn định của mô hình



Tập trung vào chuẩn hóa đầu vào để mô hình học ổn định hơn và giảm nhiễu từ dữ liệu thiếu.

Biến mục tiêu

`salary_mid` (triệu VND/tháng)

10. Dữ liệu sau xử lý

PHÂN TÍCH

Thuộc tính	Giá trị
Tổng bản ghi việc làm	1.193
Số thuộc tính (cột)	44
Nguồn dữ liệu	Itviec, Glints, TopCV, Careerviet
Tỷ lệ ẩn lương	56%
Độ phủ kỹ năng chi tiết	6.6%
Bản ghi trùng đã loại	70

1.193
tin tuyển dụng

4
nguồn dữ liệu

56%
tin ẩn lương

6.6%
độ phủ kỹ năng

11. Phân tích khám phá dữ liệu (EDA)

PHÂN TÍCH

F1 — Nhóm kỹ năng

- **Data Science & Lập trình** xuất hiện nhiều nhất trong **1.193** tin
- **Top kỹ năng:** JavaScript, React, Kafka, Python
- **Nhóm công cụ nổi bật:** SQL, Docker, Spring Boot, TensorFlow

F3 — Yêu cầu tiếng Anh

- Tin yêu cầu tiếng Anh có lương trung bình cao hơn **~30%**

F4 — Vị trí cấp cao

- **Senior, Manager, Lead** có tỷ lệ ẩn lương **>50%**


F2 — Lương tăng theo bậc kinh nghiệm

- **Entry ~10M → Mid ~17M → Senior ~28M → Lead ~35M+**
- **TP.HCM & Hà Nội** có lương trung bình cao hơn rõ rệt

12. EDA — Chart chi tiết


KẾT QUẢ

Tỷ lệ tin tuyển dụng theo từng nhóm kỹ năng




Insight: Phân bố tin tuyển dụng cho thấy sự tập trung rõ ở các nhóm kỹ năng cốt lõi.

20 kỹ năng được nhà tuyển dụng yêu cầu nhiều nhất



Insight: JavaScript, React, Python, SQL và Docker là các kỹ năng xuất hiện dày đặc nhất.

Lương trung bình theo yêu cầu tiếng Anh



Insight: Tin có yêu cầu tiếng Anh thường đi kèm mức lương cao hơn, phản ánh tính cạnh tranh của vị trí.

-  Nhóm kỹ năng có tác động mạnh đến nhu cầu tuyển dụng
-  Yêu cầu tiếng Anh liên quan đến mức lương cao hơn
-  Các kỹ năng phổ biến tập trung vào lập trình, dữ liệu và hệ thống

13. Kết quả mô hình dự báo lương

KẾT QUẢ

ML & INSIGHT


- **Linear Regression** giảm **RMSE 53.5%** so với Baseline trung bình.
- **Decision Tree** giảm **RMSE 93.3%** so với Baseline trung bình.
- **12 sai số lớn nhất** đều dưới **2.1 triệu VND**.
- **Residual** phân bố quanh mức **0 (std $\approx$ 0.6M)**, dự đoán không thiên lệch.
- **Random Forest** có dấu hiệu **overfit** trên tập dữ liệu hiện tại.

DỮ LIỆU

Mô hình	RMSE (Triệu VND)	MAE (Triệu VND)	R ² Score
Baseline (Dummy Mean)	8.97	7.36	-0.010
Linear Regression	4.17	2.94	0.783
Decision Tree	0.60	0.18	0.996
Random Forest	~0.00	~0.00	~1.000

14. SHAP — Giải thích mô hình Decision Tree

KẾT QUẢ



🤖 TreeExplainer tính đóng góp của 21 đặc trưng cho từng tin trong 105 tin kiểm thử (20% tập dữ liệu)



💡 experience_years và nhóm kỹ năng đóng góp lớn nhất — kinh nghiệm là yếu tố quyết định mức lương

📊 Đỏ đẩy lương lên, xanh kéo lương xuống — độ trải rộng của điểm màu phản ánh tác động phi tuyến của Decision Tree

SHAP summary plot (nguồn: scripts/generate_shap_plots.py)

15. Kết quả ML — Chart

KẾT QUẢ



Dữ liệu

- Sai số dự đoán (**residual**) phân bố quanh mức 0

💡 **Insight:** ưu tiên mô hình có **RMSE** thấp và **R²** cao nhất để đảm bảo dự đoán ổn định.

ML

- So sánh độ chính xác **RMSE**, **MAE**, **R²** giữa 4 mô hình

16. Phân cụm thị trường (K-Means)

KẾT QUẢ

🔍 Khảo sát số cụm k từ 2 đến 10, chọn **k = 10** với **Silhouette Score 0.38**.

**Junior-Mid Hà Nội**
15.1M

**Mid-Senior TP.HCM**
27.1M

**Senior**
41.9M

**Mid đa dạng**
20.8M



**Remote**
31.6M

Cluster	Tỷ lệ	Lương TB	Kinh nghiệm TB	Đặc điểm
0	21%	15.1M	2.6y	Junior-Mid, Hà Nội
1	14%	27.1M	2.6y	Mid-Senior, TP.HCM
4	10%	41.9M	4.8y	Senior, thu nhập cao
8	21%	20.8M	2.1y	Mid, đa dạng
9	4%	31.6M	2.7y	Việc làm Remote

💡 **Insight:** các cụm lương cao tập trung ở nhóm Senior và Remote, trong khi Junior-Mid chiếm tỷ trọng lớn nhất.

17. K-Means — Chart phân cụm

KẾT QUẢ



 Silhouette Score khi khảo sát số cụm k từ 2 đến 10

 10 cụm thị trường nhìn trên không gian 2 chiều sau PCA

 Insight: mô hình cho thấy cấu trúc phân cụm rõ ràng hơn khi tăng số cụm lên 10

18. SHAP — Giải thích mô hình Linear Regression

KẾT QUẢ

LinearExplainer


LinearExplainer tính SHAP bằng hệ số nhân giá trị đặc trưng — quan hệ 1:1, dễ đọc trên **105 tin kiểm thử**

Độ lớn SHAP

Độ lớn SHAP là đóng góp tuyệt đối vào lương (**triệu VND**), giúp so sánh trực tiếp độ quan trọng giữa các đặc trưng

Insight

Các đặc trưng quan trọng nhất khớp với Decision Tree — kết quả ổn định giữa 2 mô hình




19. Hệ thống gợi ý việc làm (Content-based)

KẾT QUẢ

 Bảng kết quả gợi ý

Việc làm	Similarity	Kỹ năng khớp	Kỹ năng thiếu
Data Scientist	1.0	Python, SQL, Machine Learning	—
ML Engineer	0.67	Python, Machine Learning	Docker, Spark
Data Engineer	0.67	Python, SQL	Spark, Airflow

 Demo hồ sơ: [Python, SQL, Machine Learning]



 **Insight:** Kỹ năng được mã hóa thành ma trận **1500 việc x 45 kỹ năng**.

Hệ thống lọc theo **thành phố** và **kinh nghiệm ±0.5 năm** trước khi tính cosine để giảm nhiễu.



20. Gợi ý — Chart similarity

KẾT LUẬN

Điểm tương đồng

Giữa hồ sơ demo và các việc trong kho

- **Ưu tiên** hiển thị các việc có similarity cao nhất
- Giúp người dùng nhanh chóng **so sánh mức độ phù hợp**



21. Kết luận

KẾT LUẬN

Pipeline khoa học dữ liệu end-to-end

Hoàn chỉnh, đáp ứng đủ các tiêu chí của học phần

- **Hồi quy:** RMSE giảm từ **8.97** (Baseline) xuống **4.17** (Linear, R^2 **0.783**) rồi **0.60** (Decision Tree, R^2 **0.996**)
-  **SHAP xác nhận** kinh nghiệm và nhóm kỹ năng là nhân tố chính quyết định lương, nhất quán giữa 2 mô hình
-  **K-Means:** $k = 10$ (Silhouette **0.38**) nhận diện **5** phân khúc thị trường rõ rệt
-  **Content-based:** gợi ý **Top-3** việc phù hợp kèm kỹ năng còn thiếu

Toàn bộ **RQ1-RQ5** được trả lời qua EDA (F1-F4), SHAP và hệ gợi ý

RMSE

0.60

Decision Tree

R^2

0.996

Decision Tree

Silhouette

0.38

$k=10$

Kết quả gợi ý

Top-3

việc phù hợp

22. Hạn chế & Hướng phát triển

KẾT LUẬN

Hạn chế của dữ liệu và mô hình

- Kỹ năng chi tiết chỉ xuất hiện trong **6.6%** tin, ảnh hưởng đến độ chính xác của đặc trưng kỹ năng
- Dữ liệu thiên lệch địa lý: **TP.HCM ~50%** tin, trong khi **Đà Nẵng ~4%**
- **Decision Tree** và **Random Forest** có dấu hiệu overfit; dùng **salary midpoint** do **56%** tin ẩn lương

Hướng phát triển trong tương lai

- **Crawler** truy cập sâu vào trang chi tiết từng tin, mở rộng số nguồn và cập nhật dữ liệu theo thời gian
- Dùng **NLP/BERT** trích xuất đặc trưng ngữ nghĩa từ mô tả công việc
- Thử **DBSCAN / Hierarchical Clustering** và **Hybrid Recommendation**

CẢM ƠN THẦY CÔ VÀ CÁC BẠN

KẾT LUẬN

ĐÃ LẮNG NGHE!

Q&A